

Das Schärfen von Bildern in Julia

Maximilian Simmoteit

13. März 2019

Grundannahmen dieser Arbeit

In dieser Arbeit werden allgemeine Bilder als Funktionen $[0, 1]^2 \rightarrow [0, 1]$ aufgefasst. Diskrete Bilder sind dann zweidimensionale Vektoren mit Werten in $[0, 1]$.

1 Das Schärfen von Bildern

In meinem Projekt habe ich mich damit beschäftigt den Algorithmus zum Schärfen von Bildern als Programm umzusetzen. Die Unschärfe eines Bildes wird hier als Faltung aufgefasst. Für einen Faltungskern k und ein Bild u ist das unscharfe Bild dann $k * u$. Für ein gegebenes unscharfe Bild f ergibt sich daraus für die Optimierung der Minimierungsterm:

$$\min_{u \in U} \|k * u - f\| + \alpha TV(u) \quad (1)$$

oder für den diskreten Fall

$$\min_{u \in U} \|k * u - f\| + \alpha \|\nabla_h u\|_2 \quad (2)$$

Zum Finden der optimalen Lösung u , kann man die Routine von Chambolle-Pock nutzen. Als Eingabe benötigt diese einen Term der Form $\min_{x \in X} F(x) + G(Ax)$. Allerdings wird der Term für ein gefaltetes Bild dem nicht ganz gerecht, da dort auch im ersten Term noch eine Funktion auf die Variable angewandt wird. Deswegen setzt man $F(x) = 0$ und setzt den gesamten Term in $G(Ax)$ ein. Hier setzt man $Au = k * u$ und dementsprechend A^* als dessen adjungierte Abbildung. Somit erhält man den folgenden Algorithmus:

$$\begin{aligned} x^{k+1} &= x^k - \tau(A^* y_1^k - \operatorname{div} y_2^k) \\ \bar{x}^{k+1} &= 2 \cdot x^{k+1} - x^k \\ y_1^{k+1} &= \frac{1}{1 + \sigma} (y_1^k + \sigma \cdot A \bar{x}^{k+1} - \sigma \cdot f) \\ y_2^{k+1} &= \frac{\alpha (y_2^{k+1} + \sigma \nabla \bar{x}^{k+1})}{\max\{\alpha, \|y_2^{k+1} + \sigma \nabla \bar{x}^{k+1}\|_2\}} \end{aligned}$$

2 Umsetzung als Programm

Und so wurde dieser Algorithmus als Programm umgesetzt.
Zuerst betrachten wir, wie die Funktionen der diskreten Ableitung implementiert wurden.

2.1 Der diskrete Gradient

Um diesen Algorithmus zu implementieren muss man auch einen Algorithmus für den diskreten Gradienten implementieren. Für den diskreten Fall gilt allgemein, dass $(\nabla_h u)_{ijk} = (\partial_k^{h,+} u)_{ij}$ für die vorwärts-Ableitung. Dieser Zusammenhang lässt sich in Julia sehr einfach umsetzen:

```
function disk_grad(u)
    return cat(disk_ab_v(u,1), disk_ab_v(u,2), dims=3)
end
```

für eine Funktion "disk ab v", die hier die diskrete vorwärts-Ableitung liefert. Das Argument "dims=3" besagt, dass die beiden zweidimensionalen Arrays zu einem dreidimensionalen zusammengefügt werden. Die diskrete vorwärts-Ableitung lässt sich mit einer einfachen Übertragung und Iteration über alle Elemente implementieren:

```
function disk_ab_v(u::Array{Float64,2}, k::Int)
    n = size(u,1)
    m = size(u,2)
    h = 1/sqrt(n*m)
    v = zeros((n,m))
    if k == 1
        for i = 1:n
            for j = 1:m
                if i < n
                    v[i, j] = (u[i+1, j] - u[i,j])/h
                else
                    v[i, j] = 0
                end
            end
        end
    elseif k == 2
        for i = 1:n
            for j = 1:m
                if j < m
                    v[i, j] = (u[i, j+1] - u[i,j])/h
                else
                    v[i, j] = 0
                end
            end
        end
    end
end
```

```

        else

        end
        return v
    end
end

```

Performance Verbesserungen

Diese Implementierung ist sehr direkt dem Lehrbuch entnommen und noch nicht für die Performance eines Computers optimiert. Als erstes, kann man "Type Annotations" einführen. Dies sagt der Programmiersprache, welche Datentypen man erwartet und erleichtert das Optimieren und kompilieren dieses Codes:

```

function disk_ab_v(u::Array{Float64,2}, k::Int)
...
function disk_grad(u::Array{Float64,2})
...

```

Als nächstes merkt man, dass die Schleifenschritte voneinander unabhängig sind (von u wird nur gelesen und v wird nur beschrieben) und man kann dieser Schleife das Makro `@simd` vorstellen. Dies kann bei vielen Prozessoren zu schnellerer Ausführung führen. Allerdings kann man das nur bei der innersten Schleife anführen, da eine einfache Instruktion auf verschiedene Daten angewandt werden kann. Um das zu verbessern, kann man die zwei Schleifen zu einer Schleife zusammen fassen. Da ich diesen Algorithmus schon mehrfach getestet habe, kann Julia darauf verzichten sogenannte "BoundsChecks" durchzuführen, mittels des `@inbounds` Makros.

```

M = n*m
@simd for a = 0:M-1
    j = a % m + 1
    i = a (ganzzahlige Division) m + 1
    if i < n
        @inbounds v[i, j] = (u[i+1, j] - u[i, j])/h
    else
        @inbounds v[i, j] = 0
    end
end
end

```

Da für k nur zwei Fälle möglich sind, kann man die if-else Verzweigung sein lassen und für die beiden vorwärts-Ableitungen eigene Funktionen schreiben. Zuletzt kann noch der Speicher verbessert werden. Bisher wurde bei jedem Aufruf, mittels $v = \text{zeros}((n, m))$, neuer Speicher vom Betriebssystem angefordert. Da in der Optimierungsschleife diese Funktion nur jeweils einmal aufgerufen wird und das Ergebnis danach nicht mehr benötigt, kann man ein Array definieren, das man in jedem Schleifendurchlauf neu beschreibt. Dies macht man folgendermaßen:

```

function perf_disk_grad(u::Array{Float64,2}, res_arr::Array{Float64,3})
    perf_disk_ab_v_1(u,res_arr)
    perf_disk_ab_v_2(u,res_arr)
end
...
function perf_disk_ab_v_1(u::Array{Float64,2},v::Array{Float64,3})
...
    if i < n
        @inbounds v[i, j, 1] = (u[i+1, j] - u[i,j])/h
    else
        @inbounds v[i, j, 1] = 0
    end
end
...
end
...

```

hier ist "res arr" ein Array in den Dimensionen der Ausgabe. Das Array wird den Funktionen jeweils übergeben "perf disk ab v 1" beschreibt die Werte $v[i,j,1]$ und "perf disk ab v 2" beschreibt die Werte $v[i,j,2]$.

2.2 Die diskrete Divergenz

Bei der diskreten Divergenz werden die Ergebnisse diskreten rückwärts-Ableitung miteinander addiert. Programmiert sieht das so aus:

```

function disk_div(u)
    return disk_ab_r(u[:, :, 1], 1) + disk_ab_r(u[:, :, 2], 2)
end

```

Die diskrete rückwärts-Ableitung lässt sich mithilfe von Schleifen auch ganz leicht nach Julia übertragen:

```

function disk_ab_r(u::Array{Float64,2}, k::Int)
    n = size(u,1)
    m = size(u,2)
    h = 1/sqrt(n*m)
    v = zeros((n,m))
    if k == 1
        for i = 1:n
            for j = 1:m
                if i == 1
                    v[i,j] = u[i,j]/h
                elseif i < n
                    v[i, j] = (u[i, j] - u[i-1,j])/h
                else
                    v[i, j] = -u[n-1,j]/h
                end
            end
        end
    end
end

```

```

        end
    elseif k == 2
        for i = 1:n
            for j = 1:m
                if j == 1
                    v[i,j] = u[i,j]/h
                elseif j < m
                    v[i, j] = (u[i, j] - u[i,j-1])/h
                else
                    v[i, j] = -u[i,m-1]/h
                end
            end
        end
    end
end
return v
end

```

Performance Verbesserungen

Auch hier ist das nur eine simple Übertragung in Julia. Wie in den vorherigen Verbesserungen kann man mittels inbounds und simd Makros die Performance verbessern. Die Verbesserung der Speichernutzung funktioniert hier allerdings etwas anders.

2.3 Die diskrete Faltung

Bei der diskreten Faltung wird ein Bild der Dimension $n \times m$ mit einem Vektor der Dimension $(2r + 1) \times (2s + 1)$ gefaltet. Da Arrays in Julia mit Index 1 anfangen, habe ich das Array zum Falten als Funktion modelliert:

```

function kreis_k(h,p,q,r,s)
    if p^2/r^2 + q^2/s^2 <= 1
        return h
    else
        return 0
    end
end

```

Damit lässt sich die diskrete Faltung wie folgt programmieren:

```

function disk_falt(u::Array{Float64,2}, r::Int, s::Int, k::Function,h::Float64)
    n_d = size(u,1)
    m_d = size(u,2)
    A = zeros((n_d-2*r, m_d-2*s))
    for i = 1:n_d-2*r

```

```

        for j = 1:m_d-2*s
            a = 0
            for n = i-r:i+r
                for m = j-s:j+s
                    a = a + u[n+r, m+s]*k(h,i-n,j-m,r,s)
                end
            end
            A[i,j] = a
        end
    end
    return A
end

```

Zuletzt fehlt noch die adjungierte Faltung. Die akzeptiert ein Array der Dimension $n \times m$ und gibt ein Array der Dimension $(n + 2r) \times (m + 2s)$ aus. Die adjungierte Faltung lässt sich wie folgt programmieren:

```

function disk_falt_adj(w::Array{Float64,2}, r::Int, s::Int, k::Function,h::F
    n_a = size(w,1)
    m_a = size(w,2)
    A = zeros((n_a + 2*r, m_a + 2*s))
    for i = 1:n_a+2*r
        for j = 1:m_a+2*s
            a = 0
            for n = max(1,i-2*r):min(i, n_a)
                for m = max(1,j-2*s):min(j, m_a)
                    a = a + w[n, m]*k(h,n-i+r,m-j+s,r,s)
                end
            end
            A[i,j] = a
        end
    end
    return A
end

```

Dass das wirklich die adjungierte Faltung ist lässt sich mit folgendem Programm überprüfen:

```

function dual_paarung(u::Array{Float64,2}, w::Array{Float64,2})
    n1 = size(u,1)
    n2 = size(u,2)
    a = 0

    for i=1:n1
        for j=1:n2
            a = a + u[i, j]*w[i, j]
        end
    end
end

```

```

        return a
    end

function teste_adj_faltung(n_wert,m_wert,r_wert,s_wert, k)
    f = 0
    for r=1:r_wert
        println("r: ",r)
        for s=1:s_wert
            for n = (n_wert-10):n_wert
                for m = (m_wert-10):m_wert
                    u = rand(Float64,(n,m))
                    w = rand(Float64,(n-2*r,m-2*s))
                    res1 = dual_paarung(w,
                        disk_falt(u,r,s,k))
                    res2 = dual_paarung(
                        disk_falt_adj(w,r,s,k),u)
                    if abs(res1-res2) > 1e-4
                        println("!Fehler: ",
                            res1, ", ", res2)
                        f = f+1
                    end
                end
            end
        end
    end
    return f
end

```

Performance Verbesserungen

Bei der Faltung und der adjungierten Faltung handelt es sich um die Flaschenhalse dieser Berechnung. Deshalb kann es sich lohnen diese Berechnung zu parallelisieren. Durch das threads Makro am Anfang der Schleifen:

```

...
@threads for i = 1:n_d-2*r
...

```

werden die $n_d - 2 \cdot r$ Schleifendurchläufe auf die Threads der Julia-Umgebung aufgeteilt. Vor dem Starten von Julia kann man mittels

```
export JULIA_NUM_THREADS=8
```

Ebenso wie bei der diskreten Divergenz und dem diskreten Gradienten lassen sich hier schon die Ergebnis Arrays übergeben, so dass keine neuen Speicherbelegungen stattfinden.

2.4 Die Optimierungsschleife

Zuerst müssen verschiedene Werte initialisiert werden:

```
function bild_schaerfer(bild::Array{Float64,2}, alpha::Float64, r::Int,
                        s::Int, k::Function, it=10000::Int)
    n_a = size(bild,1)
    m_a = size(bild,2)

    n = n_a + 2*r
    m = m_a + 2*s

    xk = embed_image(bild,r,s)
    y1k = zeros((n_a,m_a))
    y2k = zeros((n,m,2))

    tau = 1/(n*m*sqrt(8)+1)
    sigma = (1/(n*m*sqrt(8)+1))
```

xk steht hier für x^k und $y1k$ für y_1^k sowie $y2k$ für y_2^k . y wird als 0 initialisiert und x als das Eingabebild, bei dem die Ränder mit Nullen aufgefüllt sind. σ und τ sind so gewählt, dass $\sigma \cdot \tau < \frac{1}{h^2 \cdot 8}$. Damit lässt sich nun die Optimierungsschleife umsetzen. Hierbei wird jeweils $xk2, y1k2, y2k2$ für x^{k+1} geschrieben. Der erste Schritt des Algorithmus

$$x^{k+1} = x^k - \tau(A^* y_1^k - \text{div} y_2^k)$$

lässt sich somit als

$$\text{xk2} = \text{xk} - \text{tau} * (\text{disk_falt_adj}(\text{y1k}, \text{r}, \text{s}, \text{k}) - \text{disk_div}(\text{y2k}))$$

schreiben. Der zweite Schritt

$$\bar{x}^{k+1} = 2 \cdot x^{k+1} - x^k$$

ist ganz einfach

$$\text{xk3} = 2 * \text{xk2} - \text{xk}$$

und die letzten beiden Schritte

$$y_1^{k+1} = \frac{1}{1 + \sigma} (y_1^k + \sigma \cdot A \bar{x}^{k+1} - \sigma \cdot f)$$

$$y_2^{k+1} = \frac{\alpha (y_2^{k+1} + \sigma \nabla \bar{x}^{k+1})}{\max\{\alpha, \|y_2^{k+1} + \sigma \nabla \bar{x}^{k+1}\|_2\}}$$

lassen sich als

$$\text{y1k2} = (1/(1+\text{sigma})) * (\text{y1k} + \text{sigma} * \text{disk_falt}(\text{xk3}, \text{r}, \text{s}, \text{k}) - \text{sigma} * \text{bild})$$

$$\text{y2k2} = \text{alpha} * (\text{y2k} + \text{sigma} * \text{disk_grad}(\text{xk3})) / \max(\text{alpha}, \text{m_norm2_3}(\text{y2k} + \text{sigma} * \text{disk_grad}(\text{xk3})))$$

programmieren. Zuletzt müssen die neuen Variablen die alten überschreiben und die Schleife ist fertig:

```
xk = xk3  
y1k = y1k2  
y2k = y2k2)
```

Aufgrund der kleinen Schrittgrößen läuft dieses Programm eine fest vorgegebene Schrittzahl durch.

Von der Konsole kann man dieses Programm wie folgt aufrufen:

```
julia src/run_script.jl --i "exp_bilder/test_bild1_falt.png" --vr 3  
--hr 3 --a 5.0 --it 15000
```